

Relatorio Estatistico - Credit Scoring Quantum Finance

Base analisada: Base_ScoreCredito_QuantumFinance.csv | Amostra: **10.127** clientes | Alvo: SCORE_CREDITO

Resumo executivo

- A regressao linear multipla foi o modelo mais adequado entre os dois modelos testados, com R2 de 0,626 no teste e R2 medio de 0,656 em validacao cruzada.
- A arvore de decisao teve desempenho inferior, com R2 de 0,564 e erro maior; ela e util como benchmark interpretavel, mas nao superou a regressao neste conjunto.
- As variaveis com maior peso preditivo foram valor do imovel, casa propria, tempo no ultimo servico, salario, quantidade de carros e quantidade de cartoes.
- As suposicoes da regressao foram atendidas apenas parcialmente: a independencia dos residuos e adequada, mas normalidade e homocedasticidade foram rejeitadas pelos testes formais.

Quadro conceitual estatistico


Componente	Descricao
Tema	Credit scoring para credito ao consumidor.
Problema	A Quantum Finance precisa aprimorar a concessao de credito diante do aumento de inadimplencia e quer identificar clientes de menor risco.
Hipoteses conceituais	Clientes com maior patrimonio, renda, estabilidade profissional e ativos tendem a apresentar maior SCORE_CREDITO; regioes de moradia e atributos cadastrais tambem podem influenciar o risco.
Objetivo principal	Construir e avaliar um modelo preditivo para estimar o SCORE_CREDITO e apoiar analistas de credito e gerentes de conta.
Populacao de estudo	Carteira atual de clientes da Quantum Finance, com 10.127 registros e 15 colunas no arquivo disponibilizado.
Plano basico de analise	Tratamento da base; analise descritiva; correlacao; treino/teste; regressao linear multipla; arvore de decisao; avaliacao por MAE, RMSE, MAPE, R2 e validacao cruzada.
Tecnica estatistica	Regressao linear multipla com variaveis numericas padronizadas e variaveis categoricas codificadas por one-hot encoding; comparacao com arvore de decisao regressora.
Resultado principal	A regressao linear apresentou melhor equilibrio entre erro, explicabilidade e estabilidade, explicando cerca de 62,6% da variacao do score no teste.

Analise descritiva das variaveis

A base nao possui valores nulos. O campo estado_civil possui uma categoria 'na', que foi mantida como categoria informativa no modelo.

Variavel	Media	Desvio	Min	Mediana	Max
idade	46,33	8,02	26,00	46,00	73,00
Qte_dependentes	1,55	1,49	0,00	1,00	5,00

tempo_ultimoservico	34,13	8,22	7,00	34,00	57,00
vl_salario_mil	70,21	55,57	0,00	66,49	233,30
vl_imovel_em_mil	209,00	378,50	0,00	0,00	1.800,00
Qte_cartoes	1,08	0,33	1,00	1,00	4,00
Qte_carros	0,62	0,57	0,00	1,00	2,00
SCORE_CREDITO	469,50	133,81	162,00	449,60	979,65




Distribuicao das variaveis categoricas

Variavel	Distribuicao
sexo	F: 5358 (52,9%); M: 4769 (47,1%)
estado_civil	casado: 4687 (46,3%); solteiro: 3943 (38,9%); na: 749 (7,4%); divorciado: 748 (7,4%)
escola	ensino medio: 3352 (33,1%); ensino fundam: 2283 (22,5%); graduacao: 2094 (20,7%); mestrado: 1639 (16,2%); doutorado: 759 (7,5%)

Analise de correlacao

Variavel numerica	Correlacao com SCORE_CREDITO
vl_imovel_em_mil	0,537
vl_salario_mil	0,414
tempo_ultimoservico	0,384
Qte_cartoes	0,310
Qte_carros	0,253
casa_propria	0,250
trabalha	0,235
idade	0,213
Qte_dependentes	0,104
id	0,042
reg_moradia	-0,310


As maiores correlacoes positivas com o score aparecem em valor do imovel, salario, tempo no ultimo servico, quantidade de cartoes, quantidade de carros e casa propria. A variavel reg_moradia tem correlacao negativa moderada.



Modelo adequado para resolver o problema

O modelo recomendado para esta etapa e a regressao linear multipla. A escolha se justifica por tres motivos: melhor metrica no teste, melhor R2 medio em validacao cruzada e maior interpretabilidade para decisao de credito.

Modelo	MAE	RMSE	R2 teste	MAPE	R2 CV medio
Regressao Linear	61,74	81,49	0,626	14,18%	0,656
Arvore de Decisao	66,07	88,06	0,564	15,05%	0,581



Resultados e qualidade do modelo

A regressao linear obteve MAE de 61,74 pontos de score e RMSE de 81,49. Na pratica, o erro medio absoluto indica que a previsao individual costuma se afastar cerca de 61,74 pontos do score observado.

A arvore apresentou MAE de 66,07, RMSE de 88,06 e R2 de 0,564, ficando abaixo da regressao. A comparacao sugere que, com estes atributos, a relacao linear captura melhor o padrao geral da base do que uma arvore rasa.

Diagnostico das suposicoes da regressao

Suposicao	Evidencia	Conclusao
Independencia dos residuos	Durbin-Watson = 1,989	Adequada; valor proximo de 2 indica baixa autocorrelacao.
Normalidade dos residuos	Jarque-Bera p-valor = 2.33e-207	Nao atendida pelo teste formal.
Homoscedasticidade	Breusch-Pagan p-valor = 2.47e-159	Nao atendida; ha indicio de variancia nao constante.
Multicolinearidade	Maior VIF = 3,91	Sem multicolinearidade severa; VIF abaixo de 5 nas principais variaveis.

Recomendacoes sobre as variaveis do modelo

Pontos positivos

- A base traz variaveis cadastrais, patrimoniais e de renda que tem relacao estatistica relevante com o score.
- Valor do imovel, salario, tempo no ultimo servico e posse de ativos melhoram a capacidade explicativa do modelo.
- A ausencia de nulos facilita a implantacao inicial e reduz a necessidade de imputacao.

Pontos negativos e limites

- As variaveis nao sao suficientes para uma decisao final de credito sem outras fontes: faltam historico de pagamento, atrasos, renda comprometida, dividas existentes, utilizacao de limite, consultas recentes e dados de bureau.
- Algumas relacoes podem refletir proxies socioeconomicos; recomenda-se auditoria de vies, especialmente em variaveis como regio de moradia, sexo e estado civil.
- Como normalidade e homocedasticidade nao foram atendidas, inferencias de significancia devem ser usadas com cautela; para previsao, as metricas de teste e validacao cruzada sao mais relevantes.

Conclusao na comparacao com a arvore

1. A regressao linear e recomendada como modelo base por entregar menor erro e maior explicabilidade.
2. A arvore e inferior neste teste, mas ajuda a validar se ha regras nao lineares simples; neste caso, nao houve ganho.
3. Alternativas recomendadas para evolucao: Random Forest, Gradient Boosting, XGBoost/LightGBM, regressao robusta, regressao quantil e calibracao por faixas de risco.
4. Antes de usar em producao, definir politica de aprovacao por faixas, monitorar estabilidade populacional, testar vies e acompanhar performance em safras futuras.

Simulador do modelo

O script entregue treina a regressao linear, salva o pipeline e permite simular novos clientes por linha de comando:

```
python modelo_credit_scoring_quantum.py --simulate
```

A classificacao sugerida por faixa foi definida como regra operacional inicial: score abaixo de 400 = alto risco; 400 a 599 = risco medio; 600 ou mais = baixo risco. Os pontos de corte devem ser calibrados pela taxa real de inadimplencia e pelo apetite de risco da Quantum Finance.